

Informe Ejecutivo

Análisis Exploratorio de Datos: Covid-19 en Estados Unidos

Fuente de datos: The Covid Tracking Project (covidtracking.com)

Periodo analizado: enero 2020 – marzo 2021

Proyecto 3 · Bootcamp IA · Análisis Exploratorio de Datos

1. Resumen ejecutivo

Este informe resume los principales hallazgos del análisis exploratorio realizado sobre los datos diarios de Covid-19 en Estados Unidos, recopilados por The Covid Tracking Project entre enero de 2020 y marzo de 2021 (420 días de registro a nivel nacional).

Los puntos clave que cualquier responsable de toma de decisiones debería conocer son:

- **Estados Unidos atravesó tres olas de contagio claramente diferenciadas, cada una de mayor magnitud que la anterior. La tercera ola (invierno 2020-2021) multiplicó por cuatro el pico de casos diarios de la segunda ola.**
- Existe un desfase temporal predecible de 2 a 4 semanas entre el pico de contagios y el pico de fallecimientos, lo que ofrece una ventana de anticipación valiosa para la planificación de recursos sanitarios.
- La letalidad aparente del virus (CFR) cayó de forma sostenida, de un 5,8% en mayo de 2020 a un 1,8% en marzo de 2021, aunque esta mejora se explica en gran parte por el aumento de la capacidad de testeo, no solo por avances médicos.
- La presión hospitalaria sigue fielmente la curva de contagios y alcanzó su máximo histórico (más de 130.000 pacientes hospitalizados simultáneamente) durante la tercera ola, más del doble que en cualquier ola anterior.
- Las variables de gravedad hospitalaria (hospitalizados, UCI, ventiladores) están extremadamente correlacionadas entre sí (correlaciones superiores a 0,95), por lo que monitorizar una de ellas permite anticipar el comportamiento de las demás.

2. Fuente de datos y metodología

Los datos utilizados proceden de la API pública de The Covid Tracking Project, que recopiló de forma diaria estadísticas oficiales reportadas por los distintos estados de EE.UU. hasta marzo de 2021, fecha en la que el proyecto cesó su actividad.

El dataset original contenía 420 registros diarios y 25 variables. Como parte del proceso de limpieza se eliminaron cuatro columnas sin valor analítico (un campo completamente vacío y tres campos de metadatos técnicos), y la columna de fecha se convirtió a formato temporal para permitir el análisis de series de tiempo.

Se identificaron valores nulos en las variables relacionadas con hospitalización, UCI y ventilación mecánica, concentrados principalmente en los primeros meses de la pandemia (entre 51 y 79 días sin dato sobre 420). Esto se interpreta como una limitación en la capacidad de reporte durante la fase inicial de la crisis, no como ausencia real del fenómeno, por lo que estos valores se mantuvieron como datos faltantes en lugar de sustituirse por cero.

Para suavizar el ruido propio de los reportes diarios (menor actividad los fines de semana, picos los lunes) se calcularon medias móviles de 7 días sobre las principales variables de interés.

3. Hallazgos principales

3.1 Evolución de la pandemia: tres olas de intensidad creciente

La evolución de los casos diarios muestra tres olas claramente diferenciadas. La primera, en marzo-abril de 2020, alcanzó un máximo de aproximadamente 30.000 casos diarios y estuvo concentrada en el noreste del país. La segunda, en julio de 2020, llegó a unos 65.000-70.000 casos diarios, asociada al repunte estival en estados del sur. La tercera, durante el invierno de 2020-2021, fue la más severa por un amplio margen, alcanzando picos de aproximadamente 250.000 casos diarios a comienzos de enero de 2021.




Figura 1. Casos nuevos diarios de Covid-19 en EE.UU., con media móvil de 7 días.

La curva de casos acumulados refleja la misma historia desde otra perspectiva: el crecimiento es relativamente gradual hasta octubre de 2020, momento a partir del cual la pendiente se vuelve marcadamente más pronunciada, evidenciando la magnitud de la tercera ola frente a las dos anteriores.




Figura 2. Casos positivos acumulados de Covid-19 en EE.UU.

3.2 Desfase temporal entre contagios y fallecimientos

La evolución de las muertes diarias reproduce la forma de la curva de casos, pero desplazada en el tiempo. En la segunda ola, el pico de casos se produjo en julio mientras que el pico de muertes (en torno a 1.100 diarias) llegó en agosto, un desfase de 3 a 4 semanas. En la tercera ola, el pico de casos se sitúa a comienzos de enero de 2021 y el pico de muertes (alrededor de 3.300 diarias) llega a finales de enero o principios de febrero, un desfase de 2 a 3 semanas.




Figura 3. Muertes diarias por Covid-19 en EE.UU., con media móvil de 7 días.

Este patrón es coherente con la progresión clínica de la enfermedad (contagio, agravamiento, hospitalización y, en los casos más graves, fallecimiento) y constituye un indicador de anticipación: un repunte sostenido de casos permite prever, con varias semanas de margen, el impacto posterior sobre la mortalidad y la necesidad de recursos sanitarios.

3.3 Tasa de mortalidad (CFR): una tendencia descendente con matices

La tasa de mortalidad acumulada (proporción de fallecidos sobre el total de casos confirmados, o CFR) muestra una clara tendencia descendente a lo largo del periodo analizado. Tras un pico inicial en marzo de 2020 que se considera un artefacto estadístico (en ese momento el número de casos confirmados era extremadamente bajo debido a la escasa capacidad de testeo, lo que infló artificialmente el ratio), la tasa se sitúa en torno al 5,8% en mayo de 2020 y desciende de forma constante hasta estabilizarse en aproximadamente el 1,8% a partir de noviembre de 2020.




Figura 4. Tasa de mortalidad acumulada (CFR), desde abril de 2020.

Esta mejora aparente debe interpretarse con cautela. La caída del CFR responde a una combinación de factores: el incremento sostenido de la capacidad de testeo (que permitió detectar muchos más casos leves o asintomáticos, ampliando el denominador), las mejoras en los protocolos de tratamiento hospitalario, y posibles cambios en el perfil demográfico de los contagiados a lo largo del tiempo. No es posible, con estos datos, aislar el peso de cada factor por separado.

3.4 Tasa de positividad de los tests

La proporción de tests con resultado positivo presenta también un patrón de tres picos, alineado temporalmente con las tres olas de contagio. El pico más alto se observa en marzo-abril de 2020, con una positividad cercana al 21%, lo que indica que en esa fase el testeo se limitaba casi exclusivamente a casos con síntomas evidentes. El segundo pico, en julio de 2020, se sitúa en torno al 7-8%, y el tercero, en enero de 2021, alcanza el 13-14%.




Figura 5. Tasa de positividad de tests (media móvil de 7 días).

Un dato relevante es que, a pesar de la mayor capacidad de testeo disponible hacia finales de 2020, la positividad durante la tercera ola no llegó a descender a los niveles mínimos observados en verano (4-5%), lo que sugiere que la intensidad de la transmisión durante el invierno volvió a saturar la capacidad de pruebas del sistema.

3.5 Presión sobre el sistema hospitalario

El número de pacientes hospitalizados por Covid-19 en un momento dado replica con notable fidelidad la forma de la curva de casos, con un desfase de aproximadamente una a dos semanas. El máximo histórico del periodo se alcanza a mediados de enero de 2021, con cerca de 132.000 pacientes hospitalizados simultáneamente, más del doble que el pico de la segunda ola (en torno a 60.000 en julio de 2020).




Figura 6. Pacientes hospitalizados actualmente por Covid-19 en EE.UU.

3.6 Relación entre las principales variables

El análisis de correlación entre las variables más relevantes confirma varios patrones observados visualmente y aporta matices adicionales:




Figura 7. Matriz de correlación entre variables clave.

- Las variables de gravedad hospitalaria (pacientes hospitalizados, en UCI y con ventilación mecánica) están extremadamente correlacionadas entre sí (0,95-0,98), lo que indica que representan distintos niveles de un mismo fenómeno de presión sanitaria.
- Los casos diarios nuevos están fuertemente correlacionados con la hospitalización (0,90) y con el volumen de tests realizados (0,89), reforzando la idea de que los casos actúan como indicador adelantado.
- La tasa de positividad muestra una correlación prácticamente nula con los casos diarios y las muertes diarias (en torno a 0), pese a que sus picos coinciden temporalmente. Esto se explica porque la correlación lineal global no captura bien relaciones que están desplazadas en el tiempo (desfases entre olas).
- La tasa de positividad presenta una correlación negativa con el volumen de tests (-0,15), coherente con la idea de que más capacidad de testeo tiende a reducir la proporción de positivos al ampliar el universo de personas analizadas.

4. Conclusiones y recomendaciones

La narrativa que emerge de los datos es la de un sistema que mejoró progresivamente su capacidad de respuesta (más testeo, mejores tratamientos, menor letalidad relativa), pero que se vio superado en términos absolutos por la magnitud de la tercera ola, la más grave de las tres en todos los indicadores analizados.

A partir de estos hallazgos, se proponen las siguientes recomendaciones:

- Utilizar la evolución de los casos diarios como indicador de alerta temprana, dado el desfase de 1 a 4 semanas observado frente a hospitalización y mortalidad. Un repunte sostenido de casos debería activar la planificación de recursos hospitalarios con varias semanas de antelación.
- Monitorizar conjuntamente hospitalización, UCI y ventilación como un único bloque de “presión hospitalaria”, dada su altísima correlación, simplificando así el panel de seguimiento sin perder información relevante.
- Interpretar la tasa de positividad de tests como un indicador de la capacidad y cobertura del sistema de pruebas, más que como una medida directa de severidad, y combinarla siempre con el volumen absoluto de casos para una lectura correcta.
- Para futuros análisis o réplicas de esta pandemia, sería recomendable complementar este dataset con datos demográficos y por estado, lo que permitiría identificar focos geográficos y patrones poblacionales no visibles en los datos agregados a nivel nacional.
- Tratar las cifras de CFR de los primeros meses de cualquier nueva crisis sanitaria con prudencia, ya que la baja capacidad de testeo inicial tiende a inflar artificialmente la letalidad aparente.

5. Limitaciones del análisis

- Los datos corresponden a un agregado nacional de Estados Unidos; no se han analizado diferencias entre estados, que probablemente existen y son significativas.
- El dataset finaliza en marzo de 2021, por lo que no incluye el impacto de la vacunación masiva ni de variantes posteriores del virus (Delta, Ómicron).
- Las variables de hospitalización, UCI y ventilación presentan datos faltantes relevantes en los primeros meses del periodo, lo que limita la fiabilidad de las comparaciones con esa etapa inicial.
- La correlación lineal utilizada no captura adecuadamente relaciones que presentan un desfase temporal entre variables, como ocurre entre la tasa de positividad y el resto de indicadores.